

Clasificación Predictiva mediante Machine Learning

Tomas David Hernandez Soc

2024-11-24

El diagnóstico temprano de enfermedades crónicas representa uno de los retos más significativos en la medicina preventiva actual. El presente análisis utiliza información recopilada por el Instituto Nacional de Diabetes y Enfermedades Digestivas y Renales de los EE.UU., enfocada en una población de mujeres de al menos 21 años de edad con ascendencia indígena Pima. Nuestro objetivo es utilizar diferentes indicadores clínicos para predecir si una paciente tiene o no diabetes.

Durante la inspección inicial de la información, detectamos un problema importante en la calidad de los datos originales: varios registros médicos mostraban imposibilidades físicas, como mediciones de presión arterial o índice de masa corporal iguales a cero. En un escenario tradicional, la solución más rápida sería eliminar por completo a las pacientes que tuvieran algún valor erróneo o faltante. Sin embargo, descartar estas observaciones significaría perder casi la mitad de los registros, lo que sesgaría fuertemente nuestro análisis y dejaría fuera perfiles de pacientes reales.

Para solucionar esto de forma rigurosa, decidimos tratar esos valores en cero como “datos faltantes” y aplicar una técnica avanzada de recuperación de información conocida como Imputación Multivariada por Ecuaciones Encadenadas (MICE). Para entender cómo funciona MICE, imaginemos a un médico analizando un expediente incompleto. Si a una paciente le falta el registro exacto de su presión arterial, en lugar de adivinar o poner un promedio general que distorsione la realidad, el método MICE analiza el resto de sus características, como su edad, su nivel de glucosa y su masa corporal. A partir de ahí, busca patrones matemáticos comparándola con cientos de pacientes similares en la base de datos para deducir, con alta precisión, cuál debería ser ese valor clínico faltante. De esta manera, logramos rescatar el 100% de las observaciones originales, garantizando que el modelo predictivo final aprenda de una base de datos completa y confiable.

El sistema evaluará las siguientes nueve variables para realizar su diagnóstico:

- pregnant: Número de embarazos que ha tenido la paciente.
- glucose: Concentración de glucosa en plasma (prueba de tolerancia a la glucosa).
- pressure: Presión arterial diastólica (mm Hg).
- triceps: Grosor del pliegue cutáneo del tríceps (mm).
- insulin: Insulina sérica de 2 horas (μ U/ml).
- mass: Índice de masa corporal.
- pedigree: Función que evalúa el historial genético familiar de diabetes.
- age: Edad de la paciente en años.
- diabetes: Variable a predecir, indicando el resultado real de la prueba (negativo o positivo).

Con la información debidamente depurada, el primer paso de nuestra metodología consiste en realizar un análisis descriptivo. A través de una visualización detallada, observaremos cómo se distribuye cada variable predictora para identificar, a simple vista, qué indicadores clínicos muestran las diferencias más marcadas entre los grupos de pacientes sanas y diagnosticadas.




Figure 1: Distribución de variables clínicas segmentadas por diagnóstico de diabetes

Una vez reconstruida la base de datos completa, el primer paso de nuestra metodología consistió en realizar un análisis visual de las distribuciones clínicas. Generamos diagramas de caja para comparar cómo se comportan los ocho indicadores médicos entre los pacientes con resultados negativos (sanos) y positivos (diabéticos).

Este análisis exploratorio arrojó hallazgos fundamentales para el diagnóstico. Visualmente, confirmamos que la concentración de glucosa (glucose) es el indicador individual con mayor poder discriminatorio pues las pacientes con diagnóstico positivo muestran, en promedio, niveles considerablemente más altos y una separación clara respecto al grupo negativo. De igual forma, el índice de masa corporal (mass), la insulina (insulin) y la edad (age) muestran tendencias al alza en pacientes diagnosticadas, confirmando su relevancia como factores de riesgo.

Por otro lado, variables como la presión arterial (pressure) o el grosor del pliegue cutáneo (triceps) muestran una fuerte superposición entre ambos grupos. Esto nos indica a nivel directivo que estas métricas, si se evalúan de forma aislada en un consultorio, no son suficientes para emitir un diagnóstico concluyente. Sin embargo, en el siguiente paso de nuestro análisis, utilizaremos algoritmos de aprendizaje automático para combinar todas estas variables simultáneamente,

detectando patrones complejos que el ojo humano o una sola gráfica no pueden captar por sí solos.




Figure 2: Diagramas de dispersión diferenciando los dos grupos a clasificar

Manejar ocho variables médicas simultáneamente puede introducir redundancia en los sistemas automatizados, ya que algunos indicadores pueden estar midiendo fenómenos de salud similares. Para optimizar esto, aplicamos un Análisis de Componentes Principales (PCA). Esta técnica matemática nos permite comprimir la información de las ocho variables originales en nuevos “componentes” que resumen la mayor cantidad de información posible.

Para identificar qué componentes capturan la verdadera señal clínica, generamos un panel con tres diagramas de dispersión cruzando las interacciones de los primeros tres componentes (PC1, PC2 y PC3). Al observar las distribuciones, el hallazgo es contundente: en los dos primeros diagramas (donde participa el PC1), existe una separación natural y visible entre las pacientes sanas y las diagnosticadas. El Primer Componente Principal logra agrupar a la mayoría de los casos positivos hacia un extremo del espectro, marcando una clara frontera de riesgo.

En contraste, al observar el tercer diagrama en la parte inferior, que cruza únicamente el Segundo y Tercer Componente (PC3 vs PC2), la separación desaparece por completo. La gráfica muestra una nube de datos donde ambos grupos se superponen de manera caótica, lo que indica que, por sí solos, estos componentes secundarios no aportan valor discriminatorio.

Esto confirma visual y empíricamente que el Primer Componente Principal (PC1) contiene la señal predictiva más fuerte. Incorporar esta variable sintetizada en la siguiente fase de modelado será clave para aumentar la precisión del diagnóstico final sin sobrecargar los algoritmos con ruido innecesario.

Para cumplir con nuestro objetivo de predecir la presencia de diabetes en nuevas pacientes a partir de sus ocho variables clínicas, implementamos y contrastamos un total de nueve algoritmos predictivos. Nuestro portafolio de modelos abarcó desde métodos lineales y estadísticos clásicos (Regresión Logística con efectos principales e interacciones, Análisis Discriminante Lineal y Cuadrático), técnicas de regularización para selección de variables (Lasso con diferentes funciones de enlace), hasta algoritmos de clasificación probabilística (Naive Bayes), basados en distancias (K-NN optimizado) y métodos de ensamble (Random Forest con 200 árboles y búsqueda en malla para mtry).

Para garantizar la robustez metodológica y determinar el verdadero poder predictivo de los algoritmos frente a datos no vistos, utilizamos el método de validación cruzada Repeated Holdout ($B = 50$), dividiendo aleatoriamente la muestra en 80% para entrenamiento y 20% para prueba en cada iteración. Los resultados promedio se consolidan en la Tabla 1.

Table 1: Comparativa de desempeño predictivo de los algoritmos evaluados (Validación Cruzada 50 iteraciones).

Algoritmo Predictivo	Exactitud Global	Sensibilidad (Detectar Diabéticos)	Especificidad (Descartar Sanos)
LDA (Discriminante Lineal)	0.7729412	0.5588679	0.8864
Regresión Logística (Efectos Principales)	0.7721569	0.5607547	0.8842
Lasso (Liga Logit)	0.7682353	0.5362264	0.8912
Random Forest	0.7580392	0.5890566	0.8476
Naive Bayes	0.7520261	0.6150943	0.8246
Regresión Logística (Interacciones)	0.7492810	0.5747170	0.8418
QDA (Discriminante Cuadrático)	0.7454902	0.5592453	0.8442
K-NN (Vecinos Más Cercanos)	0.7321569	0.5320755	0.8382
Lasso (Liga Log)	0.7315033	0.3049057	0.9576

Al analizar las métricas de la tabla, destaca un fenómeno consistente en todos los algoritmos: existe una asimetría notable en el poder predictivo dependiendo del grupo a clasificar. Todos los modelos son altamente eficientes para identificar a las pacientes sanas (Grupo II), logrando tasas de Especificidad superiores al 82%, llegando incluso al 95% con Lasso-Log.

Sin embargo, el poder predictivo cae drásticamente (rondando el 55%) cuando intentan detectar a las pacientes que efectivamente tienen diabetes (Grupo I o Sensibilidad). Esto indica que, aunque las tasas de Exactitud Global parecen favorables y estables (todas por encima del 73%), los algoritmos tienden a sesgarse hacia predecir el estado “sano”, dificultando la detección de la enfermedad.

Considerando el contexto estrictamente clínico de este análisis, el modelo elegido para implementación es el Clasificador Naive Bayes.

Si bien el Análisis Discriminante Lineal (LDA) y la Regresión Logística de Efectos Principales obtuvieron una Exactitud Global ligeramente superior (77.29% y 77.21% respectivamente), la selección técnica en medicina no debe basarse únicamente en el acierto general. El modelo Naive Bayes es el algoritmo que logró la mayor Sensibilidad de toda la prueba (61.50%) para detectar correctamente a las pacientes diabéticas.

En un escenario de salud preventiva, el costo de un Falso Negativo (diagnosticar como sana a una mujer que en realidad tiene diabetes, perdiendo tiempo valioso para iniciar su tratamiento) es infinitamente mayor al costo de un Falso Positivo

(indicar un posible riesgo a una mujer sana, lo cual solo resultaría en un examen de laboratorio confirmatorio). Por lo tanto, el Clasificador Naive Bayes representa la decisión de negocio y médica más ética y funcional al minimizar la tasa de pacientes enfermas que pasan desapercibidas.

Oportunidades de Mejora

Durante el desarrollo de este análisis, el uso inicial del Análisis de Componentes Principales (PCA) fue fundamental para confirmar de manera exploratoria y matemática que la base de datos contenía una fuerte señal de separabilidad, capturada casi en su totalidad por el Primer Componente (PC1). No obstante, al momento de estructurar los modelos predictivos finales, se tomó la decisión analítica de prescindir de estos componentes abstractos y entrenar los algoritmos exclusivamente con las variables originales. Esta decisión responde a una necesidad crítica del sector salud: la interpretabilidad. Un diagnóstico basado directamente en “niveles elevados de glucosa e insulina” es inmediatamente accionable y comprensible para un especialista médico, mientras que un modelo basado en una variable abstracta como el “PC1” representa una caja negra que carece de utilidad práctica en un consultorio.

Sin embargo, el desarrollo de modelos de Machine Learning es un proceso iterativo. Para futuras versiones de este sistema predictivo, el desempeño general —y en particular sobre la clase positiva— podría optimizarse implementando las siguientes estrategias:

- **Ingeniería de Características Híbrida:** Integrar formalmente el Primer Componente Principal (PC1) no como un reemplazo, sino como una variable predictora adicional dentro de los modelos logísticos, buscando capturar variaciones conjuntas sin sacrificar la trazabilidad de los indicadores médicos base.
- **Optimización Exhaustiva de Hiperparámetros:** Ampliar los recursos computacionales para explorar mallas de búsqueda más extensas y precisas al evaluar el parámetro lambda en los métodos Lasso, así como evaluar variaciones más profundas en la arquitectura del Random Forest (modificando la profundidad máxima o el tamaño del nodo final).
- **Manejo de Desbalanceo de Clases:** Dado que los modelos mostraron una tendencia natural a priorizar a la clase mayoritaria (pacientes sanas), resultaría prudente aplicar técnicas de sobremuestreo sintético (como SMOTE) en la matriz de entrenamiento. Esto forzaría a los algoritmos a penalizar más severamente los errores cometidos sobre el grupo de pacientes diabéticas.

Conclusión

La detección temprana de enfermedades a través de datos requiere un delicado equilibrio entre la precisión algorítmica y la aplicabilidad operativa. Mediante la recuperación de información con imputación múltiple (MICE) y la evaluación exhaustiva de nueve algoritmos predictivos, este proyecto demuestra que es posible estructurar herramientas de soporte clínico robustas a partir de indicadores básicos.

La elección definitiva del clasificador Naive Bayes refleja el principio fundamental de la analítica aplicada a la medicina: el valor de un modelo no reside únicamente en su exactitud matemática, sino en su impacto humano. Al priorizar la sensibilidad diagnóstica, garantizamos que el sistema minimice los falsos negativos, transformando el análisis de datos en una barrera de prevención real y efectiva para la salud de las pacientes.